Guida alle feature del dataset DDoS

ML4N — Group Project 8: DDoS attacks detection and characterization

Spiegazione dettagliata delle 87 colonne di *ddos_dataset.csv* (86 feature + label), con le statistiche calcolate su 64.239 flussi e una proposta di preprocessing per ciascuna.

Proposta	Colonne
TENERE	37
RIDONDANTE	22
ELIMINARE	16
ESCLUDERE	4
DA DISCUTERE	7
TARGET	1

Prima di iniziare

Come nasce un flusso

Il dataset non contiene pacchetti ma **flussi**. Un flusso è l'insieme dei pacchetti che condividono la stessa 5-tupla: IP sorgente, IP destinazione, porta sorgente, porta destinazione e protocollo. Lo strumento che ha trasformato il traffico catturato in flussi è **CICFlowMeter** (versione 3), sviluppato dal Canadian Institute for Cybersecurity per i dataset CIC, tra cui CIC-DDoS2019 da cui proviene il vostro.

Per ogni flusso CICFlowMeter calcola circa 80 statistiche: quanti pacchetti e byte ci sono, quanto sono grandi i pacchetti, quanto tempo passa tra uno e l'altro, quali flag TCP compaiono. Ogni riga del CSV è quindi il "riassunto numerico" di una conversazione.

Inizio e fine. Il flusso inizia con il primo pacchetto visto. Un flusso TCP termina quando compare un FIN o un RST; qualsiasi flusso viene comunque chiuso dopo **120 secondi** (flow timeout). Se la conversazione continua, CICFlowMeter apre un nuovo flusso con la stessa 5-tupla.

Forward e backward

Forward (Fwd) è la direzione del primo pacchetto del flusso: da chi ha iniziato la comunicazione verso l'altro estremo. **Backward (Bwd)** è la direzione opposta, cioè le risposte. Source IP e Source Port indicano sempre chi ha mandato il primo pacchetto.

Le feature senza prefisso Fwd o Bwd (per esempio *Flow IAT Mean*, *Packet Length Mean*) considerano insieme i pacchetti di entrambe le direzioni.

Questa distinzione è centrale per i DDoS: il traffico benign è una conversazione con domande e risposte, mentre in quasi tutti gli attacchi del dataset il flusso osservato contiene solo pacchetti forward (la valanga di traffico verso la vittima) e zero pacchetti backward.

Unità di misura

Tempi in microsecondi. Il readme del progetto dice "in seconds", ma CICFlowMeter misura tutti i tempi in **microsecondi (µs)**. Lo dimostrano i dati: il valore massimo di Flow Duration è 119.999.958, cioè 119,99 s, esattamente il timeout di 120 s. Vale per Flow Duration, tutte le IAT, Active e Idle.

Lunghezze in byte e riferite al **payload**, cioè ai dati trasportati senza gli header IP e TCP/UDP. Un pacchetto TCP di solo controllo (un SYN o un ACK puro) ha quindi lunghezza 0. Fanno eccezione le colonne *Header Length*, che misurano proprio gli header.

Rate in byte al secondo o pacchetti al secondo, calcolati dividendo per la durata convertita in secondi.

Come leggere le schede

Ogni scheda descrive una colonna in tre parti: **cosa misura**, **come si calcola** e **come interpretarla** nel contesto dei DDoS. Sotto, un riquadro grigio riporta le statistiche calcolate sul vostro *ddos_dataset.csv* (64.239 flussi): valori minimo, mediano e massimo, percentuale di zeri, mediana nel benign e negli attacchi, e le classi con la mediana più alta e più bassa.

L'etichetta colorata in alto a destra è la **proposta per il preprocessing**: TENERE, ELIMINARE (costante o duplicata), RIDONDANTE (correlazione > 0,95 con una feature già tenuta, indicata nella scheda), ESCLUDERE (identificativo) o DA DISCUTERE.

La mediana è usata al posto della media perché quasi tutte le feature hanno distribuzioni molto asimmetriche, con pochi valori enormi che sposterebbero la media.

Tutte le colonne a colpo d'occhio

Le colonne nell'ordine di questa guida, con la proposta di preprocessing. Le schede delle pagine successive spiegano ognuna nel dettaglio.

#	Colonna	Gruppo	Proposta	Motivo
1	Flow ID	Identificativi del flusso	**ESCLUDERE**	identificativo, non descrive il comportamento
2	Source IP	Identificativi del flusso	**ESCLUDERE**	identificativo, non descrive il comportamento
3	Destination IP	Identificativi del flusso	**ESCLUDERE**	identificativo, non descrive il comportamento
4	Source Port	Identificativi del flusso	**DA DISCUTERE**	variabile categorica con migliaia di valori
5	Destination Port	Identificativi del flusso	**DA DISCUTERE**	variabile categorica con migliaia di valori
6	Protocol	Identificativi del flusso	**DA DISCUTERE**	utile, ma va codificata one-hot
7	Timestamp	Identificativi del flusso	**ESCLUDERE**	identificativo, non descrive il comportamento
8	Total Fwd Packets	Volume: pacchetti e byte	**TENERE**	informativa e non ridondante
9	Total Backward Packets	Volume: pacchetti e byte	**TENERE**	informativa e non ridondante
10	Total Length of Fwd Packets	Volume: pacchetti e byte	**TENERE**	informativa e non ridondante
11	Total Length of Bwd Packets	Volume: pacchetti e byte	**RIDONDANTE**	$\|r\| = 0{,}952$ con Total Backward Packets, già tenuta
12	Fwd Packet Length Max	Lunghezze dei pacchetti	**TENERE**	informativa e non ridondante
13	Fwd Packet Length Min	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}961$ con Fwd Packet Length Max, già tenuta
14	Fwd Packet Length Mean	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}974$ con Fwd Packet Length Max, già tenuta
15	Fwd Packet Length Std	Lunghezze dei pacchetti	**TENERE**	informativa e non ridondante
16	Bwd Packet Length Max	Lunghezze dei pacchetti	**TENERE**	non ridondante, ma vale 0 nel 95% dei flussi
17	Bwd Packet Length Min	Lunghezze dei pacchetti	**TENERE**	non ridondante, ma vale 0 nel 97% dei flussi
18	Bwd Packet Length Mean	Lunghezze dei pacchetti	**TENERE**	non ridondante, ma vale 0 nel 95% dei flussi
19	Bwd Packet Length Std	Lunghezze dei pacchetti	**TENERE**	non ridondante, ma vale 0 nel 98% dei flussi
20	Min Packet Length	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}961$ con Fwd Packet Length Max, già tenuta
21	Max Packet Length	Lunghezze dei pacchetti	**TENERE**	informativa e non ridondante
22	Packet Length Mean	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}970$ con Fwd Packet Length Max, già tenuta
23	Packet Length Std	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}976$ con Bwd Packet Length Std, già tenuta
24	Packet Length Variance	Lunghezze dei pacchetti	**RIDONDANTE**	è il quadrato di Packet Length Std, già tenuta
25	Average Packet Size	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}968$ con Fwd Packet Length Max, già tenuta
26	Avg Fwd Segment Size	Lunghezze dei pacchetti	**RIDONDANTE**	$\|r\| = 0{,}974$ con Fwd Packet Length Max, già tenuta

#	Colonna	Gruppo	Proposta	Motivo
27	Avg Bwd Segment Size	Lunghezze dei pacchetti	**RIDONDANTE**	|r| = 1,000 con Bwd Packet Length Mean, già tenuta
28	Flow Bytes/s	Rate e rapporti	**TENERE**	informativa e non ridondante
29	Flow Packets/s	Rate e rapporti	**TENERE**	informativa e non ridondante
30	Fwd Packets/s	Rate e rapporti	**RIDONDANTE**	|r| = 1,000 con Flow Packets/s, già tenuta
31	Bwd Packets/s	Rate e rapporti	**TENERE**	informativa e non ridondante
32	Down/Up Ratio	Rate e rapporti	**TENERE**	non ridondante, ma vale 0 nel 91% dei flussi
33	Flow Duration	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
34	Flow IAT Mean	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
35	Flow IAT Std	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
36	Flow IAT Max	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
37	Flow IAT Min	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
38	Fwd IAT Total	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 1,000 con Flow Duration, già tenuta
39	Fwd IAT Mean	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 0,986 con Flow IAT Mean, già tenuta
40	Fwd IAT Std	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 0,992 con Flow IAT Std, già tenuta
41	Fwd IAT Max	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 0,998 con Flow IAT Max, già tenuta
42	Fwd IAT Min	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 0,999 con Flow IAT Min, già tenuta
43	Bwd IAT Total	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
44	Bwd IAT Mean	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
45	Bwd IAT Std	Tempi: durata e inter-arrival time	**RIDONDANTE**	|r| = 0,982 con Bwd IAT Mean, già tenuta
46	Bwd IAT Max	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
47	Bwd IAT Min	Tempi: durata e inter-arrival time	**TENERE**	informativa e non ridondante
48	Active Mean	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 94% dei flussi
49	Active Std	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 96% dei flussi
50	Active Max	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 94% dei flussi
51	Active Min	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 94% dei flussi
52	Idle Mean	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 94% dei flussi
53	Idle Std	Attività e pausa (Active / Idle)	**TENERE**	non ridondante, ma vale 0 nel 96% dei flussi
54	Idle Max	Attività e pausa (Active / Idle)	**RIDONDANTE**	|r| = 0,986 con Flow IAT Max, già tenuta
55	Idle Min	Attività e pausa (Active / Idle)	**RIDONDANTE**	|r| = 0,966 con Idle Mean, già tenuta
56	FIN Flag Count	Flag TCP	**ELIMINARE**	costante: vale sempre 0
57	SYN Flag Count	Flag TCP	**DA DISCUTERE**	quasi costante: vale 1 solo in 38 flussi

#	Colonna	Gruppo	Proposta	Motivo
58	RST Flag Count	Flag TCP	**ELIMINARE**	identica a Fwd PSH Flags in tutte le righe
59	PSH Flag Count	Flag TCP	**ELIMINARE**	costante: vale sempre 0
60	ACK Flag Count	Flag TCP	**TENERE**	informativa e non ridondante
61	URG Flag Count	Flag TCP	**TENERE**	non ridondante, ma vale 0 nel 95% dei flussi
62	CWE Flag Count	Flag TCP	**TENERE**	non ridondante, ma vale 0 nel 97% dei flussi
63	ECE Flag Count	Flag TCP	**ELIMINARE**	costante: vale sempre 0
64	Fwd PSH Flags	Flag TCP	**TENERE**	non ridondante, ma vale 0 nel 99% dei flussi
65	Bwd PSH Flags	Flag TCP	**ELIMINARE**	costante: vale sempre 0
66	Fwd URG Flags	Flag TCP	**ELIMINARE**	costante: vale sempre 0
67	Bwd URG Flags	Flag TCP	**ELIMINARE**	costante: vale sempre 0
68	Fwd Header Length	Header e finestra TCP	**DA DISCUTERE**	37% di valori negativi
69	Bwd Header Length	Header e finestra TCP	**TENERE**	informativa e non ridondante
70	Fwd Header Length.1	Header e finestra TCP	**ELIMINARE**	identica a Fwd Header Length in tutte le righe
71	Init_Win_bytes_forward	Header e finestra TCP	**TENERE**	informativa e non ridondante
72	Init_Win_bytes_backward	Header e finestra TCP	**TENERE**	informativa e non ridondante
73	min_seg_size_forward	Header e finestra TCP	**DA DISCUTERE**	valori anomali
74	Fwd Avg Bytes/Bulk	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
75	Fwd Avg Packets/Bulk	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
76	Fwd Avg Bulk Rate	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
77	Bwd Avg Bytes/Bulk	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
78	Bwd Avg Packets/Bulk	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
79	Bwd Avg Bulk Rate	Bulk e subflow	**ELIMINARE**	costante: vale sempre 0
80	Subflow Fwd Packets	Bulk e subflow	**ELIMINARE**	identica a Total Fwd Packets in tutte le righe
81	Subflow Fwd Bytes	Bulk e subflow	**RIDONDANTE**	|r| = 1,000 con Total Length of Fwd Packets, già tenuta
82	Subflow Bwd Packets	Bulk e subflow	**ELIMINARE**	identica a Total Backward Packets in tutte le righe
83	Subflow Bwd Bytes	Bulk e subflow	**RIDONDANTE**	|r| = 0,952 con Total Backward Packets, già tenuta
84	act_data_pkt_fwd	Altre feature e label	**RIDONDANTE**	|r| = 0,997 con Total Length of Fwd Packets, già tenuta
85	SimillarHTTP	Altre feature e label	**DA DISCUTERE**	non numerica: eventualmente trasformarla in 0/1
86	Inbound	Altre feature e label	**TENERE**	informativa e non ridondante
87	label	Altre feature e label	**TARGET**	ground truth, da separare dalle feature

1. Identificativi del flusso

Queste colonne dicono chi comunica con chi, con quale protocollo e quando. Non descrivono il comportamento del flusso, e nel dataset sono legate in modo artificiale alle classi (ogni attacco usa 1-2 IP fissi). Per questo di solito si escludono dal modello.

Flow ID

ESCLUDERE

Cosa misura

La stringa che identifica il flusso, nella forma IPsrc-IPdst-portaSrc-portaDst-protocollo, per esempio 172.16.0.5-192.168.50.1-634-60495-17.

Come si calcola

È la semplice concatenazione delle cinque colonne della 5-tupla. I due IP compaiono in ordine fisso, quindi i flussi nelle due direzioni di una stessa conversazione possono avere Flow ID simili ma con le porte scambiate.

Come interpretarla

Non contiene informazione nuova rispetto alle colonne da cui è costruita ed è quasi unica per riga. Usarla come feature significherebbe far memorizzare al modello i singoli flussi.

Valori distinti	60.958	**Più frequente**	172.16.0.5-192.168.50.1-0-0-(0,0%)
Distinti nel benign	3.304	**Distinti negli attacchi**	57.654

Proposta: escludere — identificativo, non descrive il comportamento.

Source IP

ESCLUDERE

Cosa misura

L'indirizzo IP di chi ha mandato il primo pacchetto del flusso.

Come si calcola

Letto dall'header IP del primo pacchetto.

Come interpretarla

Nel dataset gli attacchi provengono da 1-2 indirizzi (per esempio 172.16.0.5, la macchina dell'attaccante nel laboratorio CIC), il benign da oltre 200. Un classificatore otterrebbe un'accuratezza altissima solo guardando l'IP, ma non avrebbe imparato nulla di generalizzabile: in una rete reale gli IP cambiano. Va esclusa, ma è utile per l'analisi esplorativa (flussi per IP).

Valori distinti	216	**Più frequente**	172.16.0.5 (90,3%)
Distinti nel benign	215	**Distinti negli attacchi**	2

Proposta: escludere — identificativo, non descrive il comportamento.

Destination IP

ESCLUDERE

Cosa misura

L'indirizzo IP del destinatario del primo pacchetto.

Come si calcola

Letto dall'header IP del primo pacchetto.

Come interpretarla

Negli attacchi è quasi sempre la vittima, 192.168.50.1 o un altro server della rete del laboratorio. Stesso discorso di Source IP: identifica la macchina, non il comportamento.

Valori distinti	245	**Più frequente**	192.168.50.1 (90,3%)
Distinti nel benign	244	**Distinti negli attacchi**	2

Proposta: escludere — identificativo, non descrive il comportamento.

Source Port

DA DISCUTERE

Cosa misura

La porta di trasporto (TCP o UDP) usata da chi ha mandato il primo pacchetto.

Come si calcola

Letta dall'header TCP/UDP del primo pacchetto. Le porte vanno da 0 a 65.535: sotto 1.024 ci sono i servizi noti (53 DNS, 80 HTTP, 443 HTTPS, 389 LDAP, 123 NTP), sopra le porte effimere scelte a caso dal sistema operativo.

Come interpretarla

In un attacco riflessivo la vittima riceve risposte *dal* servizio sfruttato, quindi ci si aspetterebbe la porta del servizio come sorgente. Nel dataset questo emerge solo in parte (ddos_dns usa la 634 nel 77% dei flussi, ddos_ldap la 900 nel 94%), mentre per gli altri attacchi le porte sono molto varie. È una variabile categorica con migliaia di valori: trattarla come numero (porta 443 "più grande" della 80) non ha senso.

Minimo	0	**Massimo**	65.518
Mediana	29.661	**Valori a zero**	0,1%
Mediana benign	52.505	**Mediana attacchi**	7.113
Mediana più alta	ddos_syn (61.195)	**Mediana più bassa**	ddos_dns (634)
Valori distinti	22.994		

Proposta: da discutere — variabile categorica con migliaia di valori.

Destination Port

DA DISCUTERE

Cosa misura

La porta di trasporto del destinatario del primo pacchetto.

Come si calcola

Letta dall'header TCP/UDP del primo pacchetto.

Come interpretarla

Nel benign la porta più frequente è la 53 (DNS, 38% dei flussi), seguita dalle porte web. Negli attacchi le porte di destinazione sono quasi tutte diverse (la più frequente copre meno dell'1% dei flussi), perché il tool d'attacco le randomizza. Fa eccezione ddos_ntp, con la porta 80 (HTTP) nel 50% dei flussi: un altro indizio che questa classe contiene molto traffico web. Distingue bene il benign ma poco i diversi attacchi tra loro.

Minimo	0	**Massimo**	65.535
Mediana	30.797	**Valori a zero**	0,1%
Mediana benign	80	**Mediana attacchi**	32.759
Mediana più alta	ddos_udp (33.892)	**Mediana più bassa**	benign (80)
Valori distinti	34.733		

Proposta: da discutere — variabile categorica con migliaia di valori.

Protocol

DA DISCUTERE

Cosa misura

Il protocollo di trasporto, codificato con il numero del campo Protocol dell'header IP.

Come si calcola

6 = TCP, 17 = UDP, 0 = HOPOPT (in pratica pacchetti di cui CICFlowMeter non ha riconosciuto il trasporto).

Come interpretarla

Separa due famiglie di attacchi. Sono UDP quasi al 100% ddos_dns, ldap, mssql, netbios, snmp, ssdp, udp e udp_lag. Sono TCP ddos_syn (come atteso) ma anche ddos_tftp e ddos_ntp, sebbene TFTP e NTP siano protocolli UDP: un indizio che queste due classi contengono soprattutto traffico diverso dall'attacco che dà loro il nome. È categorica: se la usate, codificatela con one-hot.

Minimo	0	**Massimo**	17
Mediana	17	**Valori a zero**	0,1%
Mediana benign	6	**Mediana attacchi**	17
Mediana più alta	ddos_dns (17)	**Mediana più bassa**	benign (6)
Valori distinti	3		

Proposta: da discutere — utile, ma va codificata one-hot.

Timestamp

ESCLUDERE

Cosa misura

Data e ora del primo pacchetto del flusso, con precisione al microsecondo.

Come si calcola

Registrato da CICFlowMeter durante la cattura.

Come interpretarla

Tutti i flussi sono del 1 dicembre 2018, tra le 9:17 e le 13:34. Gli attacchi sono stati lanciati uno dopo l'altro, quindi l'orario rivela quasi da solo la classe: non va usato come feature. Serve invece per lo split temporale della Section 2 e per i grafici dei flussi nel tempo.

Primo flusso	2018-12-01 09:17:11	**Ultimo flusso**	2018-12-01 13:34:27
Valori distinti	64.234		

Proposta: escludere — identificativo, non descrive il comportamento.

2. Volume: pacchetti e byte

Quanto traffico contiene il flusso, separatamente per le due direzioni. Sono le feature più facili da interpretare e tra le più utili per separare il benign, che ha risposte, dagli attacchi, che di solito non ne hanno.

Total Fwd Packets

TENERE

Cosa misura

Il numero di pacchetti inviati in direzione forward, cioè da chi ha iniziato il flusso.

Come si calcola

Contatore incrementato a ogni pacchetto forward.

Come interpretarla

Negli attacchi riflessivi molti flussi hanno 1-2 pacchetti forward: ogni risposta amplificata forma un flusso a sé. ddos_dns invece raggruppa fino a 200 pacchetti per flusso. Valori molto alti con zero backward indicano traffico unidirezionale tipico di un flood.

Minimo	1	**Massimo**	85.894
Mediana	2	**Valori a zero**	0,0%
Mediana benign	2	**Mediana attacchi**	2
Mediana più alta	ddos_dns (200)	**Mediana più bassa**	ddos_ntp (1)
Valori distinti	155		

Proposta: tenere — informativa e non ridondante.

Total Backward Packets

TENERE

Cosa misura

Il numero di pacchetti inviati in direzione backward, cioè le risposte.

Come si calcola

Contatore incrementato a ogni pacchetto backward.

Come interpretarla

È una delle feature più discriminanti. Nel benign la mediana è 2, perché ogni richiesta riceve una risposta; in quasi tutti gli attacchi è 0, perché la vittima sommersa non risponde (o le sue risposte non fanno parte del flusso). Fa eccezione ddos_ntp, che si comporta come il benign.

Minimo	0	**Massimo**	1.862
Mediana	0	**Valori a zero**	87,0%
Mediana benign	2	**Mediana attacchi**	0
Mediana più alta	benign (2)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	161		

Proposta: tenere — informativa e non ridondante.

Total Length of Fwd Packets

TENERE

Cosa misura

Il totale dei byte di payload inviati in direzione forward.

Come si calcola

Somma delle lunghezze del payload di tutti i pacchetti forward. Esclude gli header IP e TCP/UDP.

Come interpretarla

Misura quanti dati ha trasportato il flusso verso il destinatario. Negli attacchi di amplificazione (ldap, mssql, ssdp) è alta anche con pochi pacchetti, perché ogni pacchetto è pieno (1.472 byte). In ddos_syn vale 0: i SYN non trasportano dati.

Minimo	0	**Massimo**	176.000
Mediana	1.050	**Valori a zero**	21,1%
Mediana benign	66	**Mediana attacchi**	1.398
Mediana più alta	ddos_dns (88.000)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.355		

Proposta: tenere — informativa e non ridondante.

Total Length of Bwd Packets

RIDONDANTE

Cosa misura

Il totale dei byte di payload inviati in direzione backward.

Come si calcola

Somma delle lunghezze del payload dei pacchetti backward.

Come interpretarla

Zero in quasi tutti i flussi d'attacco, per lo stesso motivo di Total Backward Packets, con cui è correlata a 0,95. Nel benign riflette la dimensione delle risposte: piccola per il DNS, grande per una pagina web o un download.

Minimo	0	**Massimo**	8.829.488
Mediana	0	**Valori a zero**	94,5%
Mediana benign	114	**Mediana attacchi**	0
Mediana più alta	benign (114)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	735		

Proposta: ridondante — |r| = 0,952 con Total Backward Packets, già tenuta.

3. Lunghezze dei pacchetti

Quanto sono grandi i singoli pacchetti (payload in byte) e quanto variano. Gli attacchi generati da uno strumento automatico mandano pacchetti tutti uguali, quindi minimo, massimo e media coincidono e la deviazione standard vale 0. Il traffico umano invece mescola pacchetti piccoli (ACK, richieste) e grandi (dati).

Fwd Packet Length Max

TENERE

Cosa misura

La lunghezza del pacchetto forward più grande del flusso.

Come si calcola

Massimo delle lunghezze del payload dei pacchetti forward.

Come interpretarla

Il valore 1.472 byte, frequente negli attacchi di amplificazione, è il payload massimo di un datagramma UDP su Ethernet: 1.500 byte di MTU meno 20 di header IP meno 8 di header UDP. Indica pacchetti pieni fino al limite, cioè risposte amplificate.

Minimo	0	**Massimo**	3.564
Mediana	393	**Valori a zero**	21,1%
Mediana benign	33	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.047		

Proposta: tenere — informativa e non ridondante.

Fwd Packet Length Min

RIDONDANTE

Cosa misura

La lunghezza del pacchetto forward più piccolo.

Come si calcola

Minimo delle lunghezze del payload dei pacchetti forward.

Come interpretarla

Nel benign spesso è 0, perché tra i pacchetti forward ci sono ACK senza dati. Negli attacchi di solito è uguale al massimo. È praticamente identica a Min Packet Length, perché negli attacchi non ci sono pacchetti backward.

Minimo	0	**Massimo**	2.020
Mediana	375	**Valori a zero**	23,8%
Mediana benign	0	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	benign (0)
Valori distinti	784		

Proposta: ridondante — |r| = 0,961 con Fwd Packet Length Max, già tenuta.

Fwd Packet Length Mean

RIDONDANTE

Cosa misura

La lunghezza media dei pacchetti forward.

Come si calcola

Total Length of Fwd Packets diviso Total Fwd Packets.

Come interpretarla

Insieme a Packet Length Mean è la misura più compatta della "taglia" dei pacchetti di un attacco: circa 440 byte per ddos_dns, 1.472 per ldap/mssql/ssdp, 0 per syn. È identica ad Avg Fwd Segment Size.

Minimo	0	**Massimo**	2.666,1
Mediana	383	**Valori a zero**	21,1%
Mediana benign	31	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.731		

Proposta: ridondante — |r| = 0,974 con Fwd Packet Length Max, già tenuta.

Fwd Packet Length Std

TENERE

Cosa misura

La deviazione standard delle lunghezze dei pacchetti forward: quanto variano attorno alla media.

Come si calcola

Radice della media dei quadrati degli scarti dalla media. Vale 0 se tutti i pacchetti hanno la stessa lunghezza o se c'è un solo pacchetto.

Come interpretarla

Quasi sempre 0 negli attacchi, che mandano pacchetti identici. Valori alti indicano un mix di pacchetti piccoli e grandi, tipico delle sessioni benign (richiesta corta, risposta lunga, ACK).

Minimo	0	**Massimo**	1.248,2
Mediana	0	**Valori a zero**	86,5%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	ddos_udp (22,5)	**Mediana più bassa**	benign (0)
Valori distinti	998		

Proposta: tenere — informativa e non ridondante.

Bwd Packet Length Max

TENERE

Cosa misura

La lunghezza del pacchetto backward più grande.

Come si calcola

Massimo delle lunghezze del payload dei pacchetti backward; 0 se non ci sono pacchetti backward.

Come interpretarla

Diversa da 0 quasi solo nel benign e in ddos_ntp. Per gli attacchi è un indicatore indiretto dell'assenza di risposte.

Minimo	0	**Massimo**	37.960
Mediana	0	**Valori a zero**	94,5%
Mediana benign	55	**Mediana attacchi**	0
Mediana più alta	benign (55)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	322		

Proposta: tenere — non ridondante, ma vale 0 nel 95% dei flussi.

Bwd Packet Length Min

TENERE

Cosa misura

La lunghezza del pacchetto backward più piccolo.

Come si calcola

Minimo delle lunghezze del payload dei pacchetti backward; 0 se non ce ne sono.

Come interpretarla

Quasi sempre 0: anche nel benign le risposte includono ACK senza dati. Contiene poca informazione.

Minimo	0	**Massimo**	1.460
Mediana	0	**Valori a zero**	96,6%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	153		

Proposta: tenere — non ridondante, ma vale 0 nel 97% dei flussi.

Bwd Packet Length Mean

TENERE

Cosa misura

La lunghezza media dei pacchetti backward.

Come si calcola

Total Length of Bwd Packets diviso Total Backward Packets (0 se non ce ne sono).

Come interpretarla

Descrive la dimensione tipica delle risposte. È identica ad Avg Bwd Segment Size.

Minimo	0	**Massimo**	5.011,1
Mediana	0	**Valori a zero**	94,5%
Mediana benign	48	**Mediana attacchi**	0
Mediana più alta	benign (48)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	847		

Proposta: tenere — non ridondante, ma vale 0 nel 95% dei flussi.

Bwd Packet Length Std

TENERE

Cosa misura

La deviazione standard delle lunghezze dei pacchetti backward.

Come si calcola

Come Fwd Packet Length Std, ma sui pacchetti backward.

Come interpretarla

Correlata 0,98 con Packet Length Std: dove ci sono risposte, sono loro a creare la variabilità del flusso.

Minimo	0	**Massimo**	7.045,1
Mediana	0	**Valori a zero**	97,9%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	716		

Proposta: tenere — non ridondante, ma vale 0 nel 98% dei flussi.

Min Packet Length

RIDONDANTE

Cosa misura

La lunghezza del pacchetto più piccolo del flusso, in entrambe le direzioni.

Come si calcola

Minimo su tutti i pacchetti.

Come interpretarla

In pratica coincide con Fwd Packet Length Min (correlazione 1,00), perché il pacchetto più piccolo è quasi sempre forward.

Minimo	0	**Massimo**	1.472
Mediana	375	**Valori a zero**	23,9%
Mediana benign	0	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	benign (0)
Valori distinti	781		

Proposta: ridondante — |r| = 0,961 con Fwd Packet Length Max, già tenuta.

Max Packet Length

TENERE

Cosa misura

La lunghezza del pacchetto più grande del flusso, in entrambe le direzioni.

Come si calcola

Massimo su tutti i pacchetti.

Come interpretarla

Utile per riconoscere i pacchetti "pieni" da 1.472 byte degli attacchi di amplificazione e i pacchetti grandi dei download benign.

Minimo	0	**Massimo**	37.960
Mediana	398	**Valori a zero**	20,8%
Mediana benign	58	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.062		

Proposta: tenere — informativa e non ridondante.

Packet Length Mean

RIDONDANTE

Cosa misura

La lunghezza media di tutti i pacchetti del flusso.

Come si calcola

Media delle lunghezze del payload su entrambe le direzioni.

Come interpretarla

È la sintesi più leggibile della dimensione dei pacchetti. Negli attacchi coincide con Fwd Packet Length Mean (correlazione 0,99).

Minimo	0	**Massimo**	4.023,9
Mediana	383	**Valori a zero**	20,8%
Mediana benign	44,2	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	2.098		

Proposta: ridondante — |r| = 0,970 con Fwd Packet Length Max, già tenuta.

Packet Length Std

RIDONDANTE

Cosa misura

La deviazione standard delle lunghezze di tutti i pacchetti del flusso.

Come si calcola

Come le altre Std, su entrambe le direzioni.

Come interpretarla

Misura l'eterogeneità dei pacchetti. Bassa per gli attacchi, alta per il benign.

Minimo	0	**Massimo**	6.616,6
Mediana	0	**Valori a zero**	82,9%
Mediana benign	17,5	**Mediana attacchi**	0
Mediana più alta	ddos_udp (21,4)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	1.297		

Proposta: ridondante — |r| = 0,976 con Bwd Packet Length Std, già tenuta.

Packet Length Variance

RIDONDANTE

Cosa misura

La varianza delle lunghezze di tutti i pacchetti.

Come si calcola

È il quadrato di Packet Length Std.

Come interpretarla

Contiene esattamente la stessa informazione di Packet Length Std, ma su una scala molto più estrema (i valori sono elevati al quadrato). La correlazione di Pearson non lo coglie del tutto perché la relazione non è lineare: è comunque ridondante.

Minimo	0	**Massimo**	4,378e+07
Mediana	0	**Valori a zero**	82,9%
Mediana benign	307,2	**Mediana attacchi**	0
Mediana più alta	ddos_udp (456,3)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	1.300		

Proposta: ridondante — è il quadrato di Packet Length Std, già tenuta.

Average Packet Size

RIDONDANTE

Cosa misura

La dimensione media dei pacchetti del flusso.

Come si calcola

Byte totali diviso numero di pacchetti. Per come è implementata in CICFlowMeter il denominatore differisce di uno da quello di Packet Length Mean, per cui i due valori sono vicini ma non identici.

Come interpretarla

Correlata 0,997 con Packet Length Mean: è un doppione.

Minimo	0	**Massimo**	4.025,8
Mediana	442,2	**Valori a zero**	20,8%
Mediana benign	54,2	**Mediana attacchi**	562,5
Mediana più alta	ddos_ldap (2.208)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	2.145		

Proposta: ridondante — |r| = 0,968 con Fwd Packet Length Max, già tenuta.

Avg Fwd Segment Size

RIDONDANTE

Cosa misura

La dimensione media dei segmenti forward.

Come si calcola

In CICFlowMeter è calcolata come Total Length of Fwd Packets diviso Total Fwd Packets.

Come interpretarla

Identica a Fwd Packet Length Mean (correlazione 1,00). Il nome viene dalla terminologia TCP, dove un pacchetto è un "segmento".

Minimo	0	**Massimo**	2.666,1
Mediana	383	**Valori a zero**	21,1%
Mediana benign	31	**Mediana attacchi**	401
Mediana più alta	ddos_ldap (1.472)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.704		

Proposta: ridondante — |r| = 0,974 con Fwd Packet Length Max, già tenuta.

Avg Bwd Segment Size

RIDONDANTE

Cosa misura

La dimensione media dei segmenti backward.

Come si calcola

Total Length of Bwd Packets diviso Total Backward Packets.

Come interpretarla

Identica a Bwd Packet Length Mean (correlazione 1,00).

Minimo	0	**Massimo**	5.011,1
Mediana	0	**Valori a zero**	94,5%
Mediana benign	48	**Mediana attacchi**	0
Mediana più alta	benign (48)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	832		

Proposta: ridondante — |r| = 1,000 con Bwd Packet Length Mean, già tenuta.

4. Rate e rapporti

Quanto velocemente scorre il traffico. Un DDoS cerca di saturare la vittima, quindi produce rate molto più alti del traffico normale. Attenzione però: con flussi di durata quasi nulla il rate diventa enorme anche con soli 2 pacchetti.

Flow Bytes/s

TENERE

Cosa misura

La velocità media del flusso in byte al secondo.

Come si calcola

(Total Length of Fwd Packets + Total Length of Bwd Packets) diviso Flow Duration convertita in secondi.

Come interpretarla

Negli attacchi di amplificazione supera spesso i 10^8-10^9 byte/s, perché pacchetti grandi arrivano a distanza di 1-2 µs. Nel benign è di ordini di grandezza più bassa. Se la durata è 0 il rate è infinito: nei dataset CIC capita spesso, nel vostro file no. Conviene usarla in scala logaritmica.

Minimo	0	**Massimo**	2.944.000.000
Mediana	383.000.000	**Valori a zero**	20,8%
Mediana benign	4.633,3	**Mediana attacchi**	458.000.000
Mediana più alta	ddos_ldap (2.944.000.000)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	14.796		

Proposta: tenere — informativa e non ridondante.

Flow Packets/s

TENERE

Cosa misura

La velocità media del flusso in pacchetti al secondo.

Come si calcola

(Total Fwd Packets + Total Backward Packets) diviso Flow Duration in secondi.

Come interpretarla

Un flusso di 2 pacchetti in 1 µs vale 2.000.000 pacchetti/s: è proprio la mediana di ddos_ldap, mssql, netbios, snmp e tftp. Il benign ha mediana 192 pacchetti/s, ddos_udp solo 38, perché i suoi flussi durano a lungo. Il valore riflette più la durata brevissima dei flussi che la reale intensità dell'attacco.

Minimo	0,0526	**Massimo**	3.000.000
Mediana	1.000.000	**Valori a zero**	0,0%
Mediana benign	192,4	**Mediana attacchi**	1.000.000
Mediana più alta	ddos_ldap (2.000.000)	**Mediana più bassa**	ddos_udp (38,2)
Valori distinti	16.094		

Proposta: tenere — informativa e non ridondante.

Fwd Packets/s

RIDONDANTE

Cosa misura

La velocità dei soli pacchetti forward.

Come si calcola

Total Fwd Packets diviso Flow Duration in secondi.

Come interpretarla

Coincide con Flow Packets/s (correlazione 1,00) ovunque non ci siano risposte, cioè in quasi tutto il traffico d'attacco.

Minimo	0,0349	**Massimo**	3.000.000
Mediana	1.000.000	**Valori a zero**	0,0%
Mediana benign	96,2	**Mediana attacchi**	1.000.000
Mediana più alta	ddos_ldap (2.000.000)	**Mediana più bassa**	ddos_udp (38,2)
Valori distinti	16.017		

Proposta: ridondante — |r| = 1,000 con Flow Packets/s, già tenuta.

Bwd Packets/s

TENERE

Cosa misura

La velocità dei soli pacchetti backward.

Come si calcola

Total Backward Packets diviso Flow Duration in secondi.

Come interpretarla

0 dove non ci sono risposte. Nel benign misura quanto velocemente risponde il server.

Minimo	0	**Massimo**	2.000.000
Mediana	0	**Valori a zero**	87,0%
Mediana benign	64,2	**Mediana attacchi**	0
Mediana più alta	ddos_ntp (4.444,5)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	5.265		

Proposta: tenere — informativa e non ridondante.

Down/Up Ratio

TENERE

Cosa misura

Il rapporto tra il traffico in "download" e quello in "upload".

Come si calcola

In CICFlowMeter è Total Backward Packets diviso Total Fwd Packets, troncato a intero. Il readme lo descrive al contrario (forward su backward), ma i dati confermano la versione backward su forward.

Come interpretarla

Vale in media 1,08 nel benign, dove a ogni richiesta corrisponde circa una risposta, e circa 0 negli attacchi, dove le risposte mancano. Essendo un intero (0, 1, 2...) è grossolana, ma riassume bene l'asimmetria del flusso.

Minimo	0	**Massimo**	23
Mediana	0	**Valori a zero**	91,0%
Mediana benign	1	**Mediana attacchi**	0
Mediana più alta	benign (1)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	10		

Proposta: tenere — non ridondante, ma vale 0 nel 91% dei flussi.

5. Tempi: durata e inter-arrival time

Tutti i tempi sono in microsecondi. L'IAT (inter-arrival time) è l'intervallo tra due pacchetti consecutivi: un flusso con N pacchetti ha N-1 intervalli, e le feature ne riportano media, deviazione standard, massimo e minimo. I tempi descrivono il "ritmo" del flusso: gli attacchi sparano pacchetti a raffica, il traffico umano ha pause irregolari.

Flow Duration

TENERE

Cosa misura

La durata del flusso: il tempo tra il primo e l'ultimo pacchetto.

Come si calcola

Timestamp dell'ultimo pacchetto meno timestamp del primo, in µs. Il massimo possibile è il timeout di 120 s (120.000.000 µs).

Come interpretarla

Distingue nettamente le classi. Gli attacchi riflessivi hanno durate di 1-2 µs (flussi di 2 pacchetti consecutivi). ddos_udp e ddos_dns hanno flussi più lunghi, ddos_syn una parte di flussi che arrivano quasi al timeout. Il benign è molto vario.

Minimo	1	**Massimo**	119.999.958
Mediana	2	**Valori a zero**	0,0%
Mediana benign	20.822	**Mediana attacchi**	2
Mediana più alta	ddos_udp (104.730)	**Mediana più bassa**	ddos_ldap (1)
Valori distinti	15.718		

Proposta: tenere — informativa e non ridondante.

Flow IAT Mean

TENERE

Cosa misura

Il tempo medio tra due pacchetti consecutivi del flusso, in entrambe le direzioni.

Come si calcola

Media degli intervalli tra pacchetti successivi. Con 2 pacchetti coincide con la durata del flusso.

Come interpretarla

Un valore di pochi µs indica una raffica di pacchetti, cioè un flood. Valori di millisecondi o secondi sono tipici di un'interazione umana o di un'applicazione che aspetta risposte.

Minimo	0,5	**Massimo**	36.864.108
Mediana	2	**Valori a zero**	0,0%
Mediana benign	6.926,8	**Mediana attacchi**	2
Mediana più alta	ddos_udp (34.910)	**Mediana più bassa**	ddos_ldap (1)
Valori distinti	16.210		

Proposta: tenere — informativa e non ridondante.

Flow IAT Std

TENERE

Cosa misura
La deviazione standard degli intervalli tra pacchetti.

Come si calcola
Calcolata sugli N-1 intervalli; 0 se ci sono meno di 3 pacchetti.

Come interpretarla
Misura la regolarità del ritmo. Un tool d'attacco tende a essere regolare; il traffico benign alterna raffiche e pause.

Minimo	0	**Massimo**	4,337e+07
Mediana	0	**Valori a zero**	68,5%
Mediana benign	11.936,7	**Mediana attacchi**	0
Mediana più alta	ddos_udp (56.650,0)	**Mediana più bassa**	ddos_ldap (0)
Valori distinti	17.295		

Proposta: tenere — informativa e non ridondante.

Flow IAT Max

TENERE

Cosa misura
L'intervallo più lungo tra due pacchetti consecutivi.

Come si calcola
Massimo degli intervalli.

Come interpretarla
Rivela la pausa più lunga del flusso. È correlata 0,99 con Idle Max: le pause lunghe sono proprio quelle che CICFlowMeter conta come idle.

Minimo	1	**Massimo**	115.881.474
Mediana	2	**Valori a zero**	0,0%
Mediana benign	20.813	**Mediana attacchi**	2
Mediana più alta	ddos_udp (104.706,5)	**Mediana più bassa**	ddos_ldap (1)
Valori distinti	13.601		

Proposta: tenere — informativa e non ridondante.

Flow IAT Min

TENERE

Cosa misura
L'intervallo più breve tra due pacchetti consecutivi.

Come si calcola
Minimo degli intervalli.

Come interpretarla
Valori di 0-1 µs indicano pacchetti praticamente simultanei, tipici di un flood.

Minimo	0	**Massimo**	36.864.108
Mediana	1	**Valori a zero**	6,4%
Mediana benign	2	**Mediana attacchi**	1
Mediana più alta	ddos_ntp (3)	**Mediana più bassa**	ddos_dns (1)
Valori distinti	623		

Proposta: tenere — informativa e non ridondante.

Fwd IAT Total

RIDONDANTE

Cosa misura

Il tempo totale coperto dai pacchetti forward: dal primo all'ultimo pacchetto forward.

Come si calcola

Somma degli intervalli tra pacchetti forward consecutivi.

Come interpretarla

Quando il flusso contiene solo pacchetti forward coincide con Flow Duration (correlazione 1,00).

Minimo	0	**Massimo**	119.999.958
Mediana	2	**Valori a zero**	3,4%
Mediana benign	3	**Mediana attacchi**	2
Mediana più alta	ddos_udp (104.730)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	13.909		

Proposta: ridondante — |r| = 1,000 con Flow Duration, già tenuta.

Fwd IAT Mean

RIDONDANTE

Cosa misura

Il tempo medio tra due pacchetti forward consecutivi.

Come si calcola

Media degli intervalli considerando solo i pacchetti forward.

Come interpretarla

Negli attacchi coincide con Flow IAT Mean (correlazione 0,99), perché tutti i pacchetti sono forward.

Minimo	0	**Massimo**	3,825e+07
Mediana	2	**Valori a zero**	3,4%
Mediana benign	3	**Mediana attacchi**	2
Mediana più alta	ddos_udp (34.910)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	14.154		

Proposta: ridondante — |r| = 0,986 con Flow IAT Mean, già tenuta.

Fwd IAT Std

RIDONDANTE

Cosa misura

La deviazione standard degli intervalli tra pacchetti forward.

Come si calcola

Come Flow IAT Std, solo sui pacchetti forward.

Come interpretarla

Correlata 0,99 con Flow IAT Std.

Minimo	0	**Massimo**	6,625e+07
Mediana	0	**Valori a zero**	75,6%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	ddos_udp (56.650,0)	**Mediana più bassa**	benign (0)
Valori distinti	14.949		

Proposta: ridondante — |r| = 0,992 con Flow IAT Std, già tenuta.

Fwd IAT Max

RIDONDANTE

Cosa misura

L'intervallo massimo tra pacchetti forward consecutivi.

Come si calcola

Massimo degli intervalli forward.

Come interpretarla

Correlata 1,00 con Flow IAT Max.

Minimo	0	**Massimo**	115.881.474
Mediana	2	**Valori a zero**	3,4%
Mediana benign	3	**Mediana attacchi**	2
Mediana più alta	ddos_udp (104.706,5)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	11.862		

Proposta: ridondante — |r| = 0,998 con Flow IAT Max, già tenuta.

Fwd IAT Min

RIDONDANTE

Cosa misura

L'intervallo minimo tra pacchetti forward consecutivi.

Come si calcola

Minimo degli intervalli forward.

Come interpretarla

Correlata 1,00 con Flow IAT Min.

Minimo	0	**Massimo**	36.864.108
Mediana	1	**Valori a zero**	9,0%
Mediana benign	2	**Mediana attacchi**	1
Mediana più alta	benign (2)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	165		

Proposta: ridondante — |r| = 0,999 con Flow IAT Min, già tenuta.

Bwd IAT Total

TENERE

Cosa misura

Il tempo coperto dai pacchetti backward: dal primo all'ultimo pacchetto backward.

Come si calcola

Somma degli intervalli tra pacchetti backward consecutivi; 0 con meno di 2 pacchetti backward.

Come interpretarla

Diversa da 0 quasi solo nel benign. Indica per quanto tempo il server ha continuato a rispondere.

Minimo	0	**Massimo**	119.841.028
Mediana	0	**Valori a zero**	88,4%
Mediana benign	3	**Mediana attacchi**	0
Mediana più alta	benign (3)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	2.115		

Proposta: tenere — informativa e non ridondante.

Bwd IAT Mean

TENERE

Cosa misura

Il tempo medio tra due pacchetti backward consecutivi.

Come si calcola

Media degli intervalli backward; 0 con meno di 2 pacchetti backward.

Come interpretarla

Descrive il ritmo delle risposte. Correlata 0,98 con Bwd IAT Std.

Minimo	0	**Massimo**	3,991e+07
Mediana	0	**Valori a zero**	88,4%
Mediana benign	3	**Mediana attacchi**	0
Mediana più alta	benign (3)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	2.127		

Proposta: tenere — informativa e non ridondante.

Bwd IAT Std

RIDONDANTE

Cosa misura

La deviazione standard degli intervalli tra pacchetti backward.

Come si calcola

Come le altre Std, sui pacchetti backward.

Come interpretarla

Ridondante con Bwd IAT Mean.

Minimo	0	**Massimo**	6,913e+07
Mediana	0	**Valori a zero**	96,5%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	2.099		

Proposta: ridondante — |r| = 0,982 con Bwd IAT Mean, già tenuta.

Bwd IAT Max

TENERE

Cosa misura

L'intervallo massimo tra pacchetti backward consecutivi.

Come si calcola

Massimo degli intervalli backward.

Come interpretarla

Diversa da 0 quasi solo nel benign.

Minimo	0	**Massimo**	119.744.177
Mediana	0	**Valori a zero**	88,4%
Mediana benign	3	**Mediana attacchi**	0
Mediana più alta	benign (3)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	2.055		

Proposta: tenere — informativa e non ridondante.

Bwd IAT Min

TENERE

Cosa misura

L'intervallo minimo tra pacchetti backward consecutivi.

Come si calcola

Minimo degli intervalli backward.

Come interpretarla

Diversa da 0 quasi solo nel benign.

Minimo	0	**Massimo**	258
Mediana	0	**Valori a zero**	88,9%
Mediana benign	2	**Mediana attacchi**	0
Mediana più alta	benign (2)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	44		

Proposta: tenere — informativa e non ridondante.

6. Attività e pausa (Active / Idle)

CICFlowMeter divide il flusso in periodi di attività separati da pause. Una pausa conta come "idle" quando supera la soglia di inattività del tool (5 secondi, cioè 5.000.000 µs). Nel vostro dataset circa il 94% dei flussi non ha nessuna pausa così lunga, quindi queste otto feature valgono 0 quasi ovunque.

Active Mean

TENERE

Cosa misura

La durata media dei periodi di attività del flusso.

Come si calcola

Il flusso viene spezzato nei punti in cui c'è una pausa più lunga della soglia; per ogni pezzo si misura la durata, poi la media.

Come interpretarla

Diversa da 0 solo nei flussi lunghi con pause, quasi tutti benign. Per la maggior parte delle righe non dice nulla.

Minimo	0	**Massimo**	1,679e+07
Mediana	0	**Valori a zero**	94,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1.552		

Proposta: tenere — non ridondante, ma vale 0 nel 94% dei flussi.

Active Std

TENERE

Cosa misura

La deviazione standard della durata dei periodi di attività.

Come si calcola

Calcolata sulle durate dei periodi attivi.

Come interpretarla

Quasi sempre 0.

Minimo	0	**Massimo**	2,854e+07
Mediana	0	**Valori a zero**	96,3%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1.703		

Proposta: tenere — non ridondante, ma vale 0 nel 96% dei flussi.

Active Max

TENERE

Cosa misura

Il periodo di attività più lungo.

Come si calcola

Massimo delle durate dei periodi attivi.

Come interpretarla

Quasi sempre 0.

Minimo	0	**Massimo**	67.834.732
Mediana	0	**Valori a zero**	94,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	929		

Proposta: tenere — non ridondante, ma vale 0 nel 94% dei flussi.

Active Min

TENERE

Cosa misura

Il periodo di attività più breve.

Come si calcola

Minimo delle durate dei periodi attivi.

Come interpretarla

Quasi sempre 0.

Minimo	0	**Massimo**	8.349.846
Mediana	0	**Valori a zero**	94,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	697		

Proposta: tenere — non ridondante, ma vale 0 nel 94% dei flussi.

Idle Mean

TENERE

Cosa misura

La durata media delle pause lunghe del flusso.

Come si calcola

Media delle pause che superano la soglia di inattività.

Come interpretarla

Tipica di connessioni benign tenute aperte (keep-alive) con lunghi silenzi. Correlata 0,97 con Idle Min e 0,96 con Idle Max.

Minimo	0	**Massimo**	114.745.523
Mediana	0	**Valori a zero**	93,8%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	3.982		

Proposta: tenere — non ridondante, ma vale 0 nel 94% dei flussi.

Idle Std

TENERE

Cosa misura
La deviazione standard delle pause lunghe.

Come si calcola
Calcolata sulle durate delle pause oltre soglia.

Come interpretarla
Quasi sempre 0.

Minimo	0	**Massimo**	5,275e+07
Mediana	0	**Valori a zero**	95,6%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	2.853		

Proposta: tenere — non ridondante, ma vale 0 nel 96% dei flussi.

Idle Max

RIDONDANTE

Cosa misura
La pausa lunga più lunga.

Come si calcola
Massimo delle pause oltre soglia.

Come interpretarla
Correlata 0,99 con Flow IAT Max: la pausa più lunga del flusso è la stessa cosa vista da due feature diverse.

Minimo	0	**Massimo**	114.745.523
Mediana	0	**Valori a zero**	93,8%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	3.978		

Proposta: ridondante — |r| = 0,986 con Flow IAT Max, già tenuta.

Idle Min

RIDONDANTE

Cosa misura
La pausa lunga più breve.

Come si calcola
Minimo delle pause oltre soglia.

Come interpretarla
Ridondante con Idle Mean.

Minimo	0	**Massimo**	114.745.523
Mediana	0	**Valori a zero**	93,8%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	3.977		

Proposta: ridondante — |r| = 0,966 con Idle Mean, già tenuta.

7. Flag TCP

I flag sono 8 bit dell'header TCP che indicano il ruolo del pacchetto nella connessione (apertura, conferma, chiusura...). Nei flussi UDP valgono sempre 0. Nel vostro dataset ogni conteggio vale solo 0 o 1, quindi funziona come indicatore "il flag compare almeno una volta / mai". Diversi conteggi sono incoerenti tra loro, segno di imprecisioni di CICFlowMeter.

FIN Flag Count

ELIMINARE

Cosa misura

Quanti pacchetti del flusso hanno il flag FIN (finish), che chiude in modo ordinato la connessione.

Come si calcola

Contatore dei pacchetti con il bit FIN attivo.

Come interpretarla

Sempre 0 nel dataset, anche se le connessioni benign dovrebbero chiudersi con un FIN. Probabilmente il pacchetto FIN termina il flusso e non viene contato. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

SYN Flag Count

DA DISCUTERE

Cosa misura

Quanti pacchetti hanno il flag SYN (synchronize), che apre una connessione TCP.

Come si calcola

Contatore dei pacchetti con il bit SYN attivo.

Come interpretarla

Vale 1 solo in 38 flussi su 64.239 (28 benign) e mai in ddos_syn, che pure è un SYN flood. Il SYN flood si riconosce invece dalla finestra iniziale (Init_Win_bytes_forward). Quasi costante: poca informazione.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	99,9%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: da discutere — quasi costante: vale 1 solo in 38 flussi.

RST Flag Count

ELIMINARE

Cosa misura

Quanti pacchetti hanno il flag RST (reset), che chiude bruscamente la connessione.

Come si calcola

Contatore dei pacchetti con il bit RST attivo.

Come interpretarla

Identica riga per riga a Fwd PSH Flags: lo stesso valore in tutte le 64.239 righe, quindi una delle due va eliminata. Un RST si manda quando arriva un pacchetto su una porta chiusa o per una connessione che non esiste.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	99,1%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: eliminare — identica a Fwd PSH Flags in tutte le righe.

PSH Flag Count

ELIMINARE

Cosa misura

Quanti pacchetti hanno il flag PSH (push), che chiede di consegnare subito i dati all'applicazione.

Come si calcola

Contatore dei pacchetti con il bit PSH attivo, in entrambe le direzioni.

Come interpretarla

Sempre 0, mentre Fwd PSH Flags vale 1 in 587 flussi: un'incoerenza, perché il totale dovrebbe includere la direzione forward. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

ACK Flag Count

TENERE

Cosa misura

Quanti pacchetti hanno il flag ACK (acknowledgment), che conferma la ricezione dei dati.

Come si calcola

Contatore dei pacchetti con il bit ACK attivo.

Come interpretarla

Vale 1 in 12.236 flussi: quasi tutti quelli di ddos_syn (5.479) e ddos_tftp (5.257), poi 1.094 benign e 353 ddos_ntp. Sorprende che il SYN flood abbia ACK e non SYN: probabilmente CICFlowMeter ha catturato soprattutto i pacchetti successivi all'apertura. È comunque una feature molto utile per riconoscere syn e tftp.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	81,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	ddos_syn (1)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: tenere — informativa e non ridondante.

URG Flag Count

TENERE

Cosa misura

Quanti pacchetti hanno il flag URG (urgent), che segnala dati urgenti. Oggi non si usa quasi più.

Come si calcola

Contatore dei pacchetti con il bit URG attivo.

Come interpretarla

Vale 1 in 3.072 flussi (2.357 benign, 620 ddos_ntp), ma Fwd URG Flags e Bwd URG Flags sono sempre 0: un'altra incoerenza del tool. Da usare con cautela.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	95,2%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	ddos_ntp (1)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: tenere — non ridondante, ma vale 0 nel 95% dei flussi.

CWE Flag Count

TENERE

Cosa misura

Quanti pacchetti hanno il flag CWR (Congestion Window Reduced). Nel dataset è chiamato per errore CWE.

Come si calcola

Contatore dei pacchetti con il bit CWR attivo.

Come interpretarla

Il mittente attiva CWR per confermare di aver ridotto la finestra di congestione dopo aver ricevuto un ECE. Vale 1 in 2.216 flussi (1.524 benign, 612 ddos_ntp) anche se ECE è sempre 0: un'incoerenza, perché CWR dovrebbe arrivare solo dopo un ECE.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	96,6%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	ddos_ntp (1)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: tenere — non ridondante, ma vale 0 nel 97% dei flussi.

ECE Flag Count

ELIMINARE

Cosa misura

Quanti pacchetti hanno il flag ECE (ECN-Echo), con cui il ricevitore avvisa il mittente che un router ha segnalato congestione.

Come si calcola

Contatore dei pacchetti con il bit ECE attivo.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Fwd PSH Flags

TENERE

Cosa misura

Quanti pacchetti forward hanno il flag PSH.

Come si calcola

Contatore dei pacchetti forward con il bit PSH attivo.

Come interpretarla

Vale 1 in 587 flussi, quasi tutti benign (571). È identica a RST Flag Count, il che fa pensare a un errore di mappatura delle colonne in CICFlowMeter.

Minimo	0	**Massimo**	1
Mediana	0	**Valori a zero**	99,1%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: tenere — non ridondante, ma vale 0 nel 99% dei flussi.

Bwd PSH Flags

ELIMINARE

Cosa misura

Quanti pacchetti backward hanno il flag PSH.

Come si calcola

Contatore dei pacchetti backward con il bit PSH attivo.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Fwd URG Flags

ELIMINARE

Cosa misura

Quanti pacchetti forward hanno il flag URG.

Come si calcola

Contatore dei pacchetti forward con il bit URG attivo.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Bwd URG Flags

ELIMINARE

Cosa misura

Quanti pacchetti backward hanno il flag URG.

Come si calcola

Contatore dei pacchetti backward con il bit URG attivo.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

8. Header e finestra TCP

Queste feature vengono dagli header dei pacchetti invece che dal payload. La finestra iniziale in particolare dipende dal sistema operativo o dal tool che genera il traffico, e per questo funziona come una sua "impronta digitale".

Fwd Header Length

DA DISCUTERE

Cosa misura

I byte totali occupati dagli header dei pacchetti forward.

Come si calcola

Somma delle lunghezze degli header di trasporto dei pacchetti forward (20 byte per un header TCP senza opzioni, 8 per UDP).

Come interpretarla

Fisicamente non può essere negativa, ma nel dataset lo è nel 37% dei flussi (per esempio -97 o -200). È un bug noto di CICFlowMeter, probabilmente un overflow del contatore. Va corretta o eliminata.

Minimo	-212.543.795.000	**Massimo**	155.938
Mediana	28	**Valori a zero**	8,0%
Mediana benign	40	**Mediana attacchi**	16
Mediana più alta	ddos_dns (1.600)	**Mediana più bassa**	ddos_udp (-4)
Valori distinti	1.273	**Valori negativi**	36,71%

Proposta: da discutere — 37% di valori negativi.

Bwd Header Length

TENERE

Cosa misura

I byte totali occupati dagli header dei pacchetti backward.

Come si calcola

Somma delle lunghezze degli header dei pacchetti backward.

Come interpretarla

0 dove non ci sono risposte. Ha pochissimi valori negativi (1 flusso).

Minimo	-2.125.437.950	**Massimo**	37.264
Mediana	0	**Valori a zero**	87,0%
Mediana benign	40	**Mediana attacchi**	0
Mediana più alta	ddos_ntp (64)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	268	**Valori negativi**	0,00%

Proposta: tenere — informativa e non ridondante.

Fwd Header Length.1

ELIMINARE

Cosa misura

Una copia della colonna Fwd Header Length.

Come si calcola

CICFlowMeter scrive due volte la stessa grandezza; pandas aggiunge ".1" al nome per distinguere le due colonne.

Come interpretarla

Identica a Fwd Header Length in tutte le righe. Da eliminare.

Minimo	-212.543.795.000	**Massimo**	155.938
Mediana	28	**Valori a zero**	8,0%
Mediana benign	40	**Mediana attacchi**	16
Mediana più alta	ddos_dns (1.600)	**Mediana più bassa**	ddos_udp (-4)
Valori distinti	1.273	**Valori negativi**	36,71%

Proposta: eliminare — identica a Fwd Header Length in tutte le righe.

Init_Win_bytes_forward

TENERE

Cosa misura

La dimensione della finestra TCP annunciata nel primo pacchetto forward: quanti byte il mittente è pronto a ricevere prima di dover mandare un ACK.

Come si calcola

Valore del campo Window dell'header TCP nel primo pacchetto forward. Vale -1 se il flusso non è TCP.

Come interpretarla

La finestra iniziale dipende dal sistema operativo: 64.240 (= 44 × 1.460) è tipico di Windows, 65.535 è il massimo senza window scaling, 5.840 (= 4 × 1.460) era il default di Linux 2.6. È la feature che riconosce ddos_syn: vale 5.840 nel 100% dei suoi flussi. Lo stesso valore compare nel 99,9% di ddos_tftp, che quindi è probabilmente generato dallo stesso tool. Vale -1 per tutti gli attacchi UDP.

Minimo	-1	**Massimo**	65.535
Mediana	-1	**Valori a zero**	0,1%
Mediana benign	253	**Mediana attacchi**	-1
Mediana più alta	ddos_syn (5.840)	**Mediana più bassa**	ddos_dns (-1)
Valori distinti	332	**Valori negativi**	76,17%

Proposta: tenere — informativa e non ridondante.

Init_Win_bytes_backward

TENERE

Cosa misura

La dimensione della finestra TCP nel primo pacchetto backward.

Come si calcola

Valore del campo Window nel primo pacchetto backward. Vale -1 se non è TCP o non ci sono pacchetti backward.

Come interpretarla

-1 nel 90% dei flussi. Gli altri valori riguardano quasi solo il benign e descrivono il sistema operativo del server che risponde.

Minimo	-1	**Massimo**	65.535
Mediana	-1	**Valori a zero**	4,1%
Mediana benign	-1	**Mediana attacchi**	-1
Mediana più alta	ddos_ntp (235)	**Mediana più bassa**	benign (-1)
Valori distinti	317	**Valori negativi**	90,32%

Proposta: tenere — informativa e non ridondante.

min_seg_size_forward

DA DISCUTERE

Cosa misura

La dimensione minima dell'header dei pacchetti forward.

Come si calcola

Minimo delle lunghezze dell'header di trasporto tra i pacchetti forward: 20 byte è un header TCP senza opzioni, 32 un header con opzioni.

Come interpretarla

Il nome suggerisce la dimensione minima del segmento, ma CICFlowMeter misura l'header. Nel benign è 20 o 32; altrove compaiono -1 e valori assurdi (per esempio -1.062.718.975), segno di un altro errore del tool. Poco affidabile.

Minimo	-1.062.718.975	**Massimo**	1.480
Mediana	14	**Valori a zero**	8,7%
Mediana benign	20	**Mediana attacchi**	8
Mediana più alta	ddos_ntp (32)	**Mediana più bassa**	ddos_snmp (-1)
Valori distinti	27	**Valori negativi**	36,72%

Proposta: da discutere — valori anomali.

9. Bulk e subflow

Due concetti di CICFlowMeter che descrivono la struttura interna del flusso. Nel vostro dataset sono inutili: le feature bulk sono sempre 0 e le feature subflow sono copie dei totali.

Fwd Avg Bytes/Bulk

ELIMINARE

Cosa misura

Il numero medio di byte per bulk in direzione forward. Un bulk è una raffica di almeno 4 pacchetti con dati inviati nella stessa direzione senza pacchetti nell'altra direzione in mezzo, come durante un download.

Come si calcola

Byte totali dei bulk forward diviso il numero di bulk.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Fwd Avg Packets/Bulk

ELIMINARE

Cosa misura

Il numero medio di pacchetti per bulk in direzione forward.

Come si calcola

Pacchetti totali dei bulk forward diviso il numero di bulk.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Fwd Avg Bulk Rate

ELIMINARE

Cosa misura

La velocità media dei bulk forward, in byte al secondo.

Come si calcola

Byte dei bulk forward diviso la loro durata.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Bwd Avg Bytes/Bulk

ELIMINARE

Cosa misura

Il numero medio di byte per bulk in direzione backward.

Come si calcola

Come la versione forward, sui pacchetti backward.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Bwd Avg Packets/Bulk

ELIMINARE

Cosa misura

Il numero medio di pacchetti per bulk in direzione backward.

Come si calcola

Come la versione forward, sui pacchetti backward.

Come interpretarla

Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Bwd Avg Bulk Rate

ELIMINARE

Cosa misura
La velocità media dei bulk backward.

Come si calcola
Come la versione forward, sui pacchetti backward.

Come interpretarla
Sempre 0. Costante: da eliminare.

Minimo	0	**Massimo**	0
Mediana	0	**Valori a zero**	100,0%
Mediana benign	0	**Mediana attacchi**	0
Mediana più alta	benign (0)	**Mediana più bassa**	benign (0)
Valori distinti	1		

Proposta: eliminare — costante: vale sempre 0.

Subflow Fwd Packets

ELIMINARE

Cosa misura
Il numero medio di pacchetti forward per subflow. Un subflow è un pezzo del flusso separato dagli altri da una pausa.

Come si calcola
Total Fwd Packets diviso il numero di subflow.

Come interpretarla
Nel dataset ogni flusso ha un solo subflow, quindi è identica a Total Fwd Packets in tutte le righe. Da eliminare.

Minimo	1	**Massimo**	85.894
Mediana	2	**Valori a zero**	0,0%
Mediana benign	2	**Mediana attacchi**	2
Mediana più alta	ddos_dns (200)	**Mediana più bassa**	ddos_ntp (1)
Valori distinti	155		

Proposta: eliminare — identica a Total Fwd Packets in tutte le righe.

Subflow Fwd Bytes

RIDONDANTE

Cosa misura
Il numero medio di byte forward per subflow.

Come si calcola
Total Length of Fwd Packets diviso il numero di subflow.

Come interpretarla
Correlata 1,00 con Total Length of Fwd Packets. Da eliminare.

Minimo	0	**Massimo**	176.000
Mediana	1.050	**Valori a zero**	21,1%
Mediana benign	66	**Mediana attacchi**	1.398
Mediana più alta	ddos_dns (88.000)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	1.355		

Proposta: ridondante — |r| = 1,000 con Total Length of Fwd Packets, già tenuta.

Subflow Bwd Packets

ELIMINARE

Cosa misura

Il numero medio di pacchetti backward per subflow.

Come si calcola

Total Backward Packets diviso il numero di subflow.

Come interpretarla

Identica a Total Backward Packets in tutte le righe. Da eliminare.

Minimo	0	**Massimo**	1.862
Mediana	0	**Valori a zero**	87,0%
Mediana benign	2	**Mediana attacchi**	0
Mediana più alta	benign (2)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	161		

Proposta: eliminare — identica a Total Backward Packets in tutte le righe.

Subflow Bwd Bytes

RIDONDANTE

Cosa misura

Il numero medio di byte backward per subflow.

Come si calcola

Total Length of Bwd Packets diviso il numero di subflow.

Come interpretarla

Correlata 1,00 con Total Length of Bwd Packets. Da eliminare.

Minimo	0	**Massimo**	8.829.488
Mediana	0	**Valori a zero**	94,5%
Mediana benign	114	**Mediana attacchi**	0
Mediana più alta	benign (114)	**Mediana più bassa**	ddos_dns (0)
Valori distinti	735		

Proposta: ridondante — |r| = 0,952 con Total Backward Packets, già tenuta.

10. Altre feature e label

Le ultime colonne: un conteggio dei pacchetti con dati, due campi aggiunti dal laboratorio CIC e la ground truth.

act_data_pkt_fwd

RIDONDANTE

Cosa misura

Il numero di pacchetti forward che trasportano dati, cioè con payload maggiore di 0.

Come si calcola

Contatore dei pacchetti forward con payload non vuoto.

Come interpretarla

Separa i pacchetti di dati da quelli di solo controllo (SYN, ACK). La mediana è 0 in ddos_syn, ddos_tftp e ddos_ntp, 199 in ddos_dns. Nel dataset è correlata 0,997 con Total Length of Fwd Packets, quindi ridondante.

Minimo	0	**Massimo**	399
Mediana	1	**Valori a zero**	21,4%
Mediana benign	1	**Mediana attacchi**	1
Mediana più alta	ddos_dns (199)	**Mediana più bassa**	ddos_ntp (0)
Valori distinti	83		

Proposta: ridondante — |r| = 0,997 con Total Length of Fwd Packets, già tenuta.

SimillarHTTP

DA DISCUTERE

Cosa misura

Il readme la descrive come una "misura di somiglianza con HTTP", ma in realtà contiene l'host o l'URL HTTP richiesto nel flusso, quando CICFlowMeter riesce a leggerlo.

Come si calcola

Estratta dal contenuto dei pacchetti HTTP; 0 se non c'è traffico HTTP leggibile.

Come interpretarla

Vale 0 in 63.761 flussi; negli altri contiene stringhe come 205.174.165.72/c.php o ocsp.digicert.com/. Non è numerica: per usarla andrebbe trasformata, per esempio in un indicatore 0/1 "il flusso contiene una richiesta HTTP". Pandas la legge con tipi misti (warning DtypeWarning).

Valori distinti	187	**Più frequente**	0 (99,3%)
Distinti nel benign	161	**Distinti negli attacchi**	27

Proposta: da discutere — non numerica: eventualmente trasformarla in 0/1.

Inbound

TENERE

Cosa misura

Indica la direzione del flusso rispetto alla rete della vittima: 1 se è diretto verso l'interno, 0 se esce.

Come si calcola

Campo aggiunto dal laboratorio CIC in base agli indirizzi IP della rete interna.

Come interpretarla

Vale 1 per quasi tutti i flussi d'attacco e 0 per l'81% del benign. È molto discriminante, ma dipende da come è stato costruito il laboratorio (quali IP sono "interni"). Usarla è legittimo, ma nel report va detto che il risultato potrebbe non generalizzare a un'altra rete.

Minimo	0	**Massimo**	1
Mediana	1	**Valori a zero**	8,0%
Mediana benign	0	**Mediana attacchi**	1
Mediana più alta	ddos_dns (1)	**Mediana più bassa**	benign (0)
Valori distinti	2		

Proposta: tenere — informativa e non ridondante.

label

TARGET

Cosa misura

La classe del flusso: la ground truth da predire nella classificazione e da usare per valutare il clustering.

Come si calcola

Assegnata dagli autori del dataset in base a orari, IP, porte e protocolli degli attacchi lanciati.

Come interpretarla

12 valori: benign e 11 attacchi. Le classi sono bilanciate (circa 5.300-6.000 flussi ciascuna) tranne ddos_ntp, che ha 986 flussi. Non è una feature: va separata dalla matrice X prima di qualsiasi addestramento.

Classi	12	**Più numerosa**	ddos_udp_lag (5.986)
Meno numerosa	ddos_ntp (986)		

Proposta: target — ground truth, da separare dalle feature.

Riepilogo e stranezze da citare nel report

Delle 86 colonne (escluso label), la proposta ne tiene **37**, ne lascia **7** da discutere e ne scarta le altre: 16 costanti o duplicate, 22 ridondanti (|r| > 0,95) e 4 identificativi. La scelta della feature da tenere dentro ogni gruppo correlato segue l'ordine delle colonne: si può cambiare a favore di quella più interpretabile.

1. I tempi sono in microsecondi, non in secondi come dice il readme (Flow Duration massima = 119.999.958 = timeout di 120 s).

2. Down/Up Ratio è backward su forward, non il contrario.

3. Flag TCP incoerenti: FIN e PSH sempre 0, SYN quasi assente anche nel SYN flood, URG e CWR presenti senza i corrispondenti flag direzionali o senza ECE, RST identico a Fwd PSH Flags.

4. Valori impossibili: Fwd Header Length negativa nel 37% dei flussi, min_seg_size_forward con valori come -1.062.718.975.

5. Classi sospette: ddos_syn e ddos_tftp sono quasi identiche (TCP, finestra iniziale 5.840, ACK presente); ddos_tftp e ddos_ntp sono TCP anche se TFTP e NTP sono protocolli UDP, e ddos_ntp somiglia molto al benign (porta 80, risposte presenti). Aspettatevi confusione tra queste classi nella classificazione.

6. Feature "facili" ma pericolose: IP, Timestamp e Inbound separano le classi per come è stato costruito il laboratorio, non per il comportamento del traffico. Un modello che le usa può sembrare perfetto ma non generalizzare.